Análisis de la Arquitectura Empresarial de Amazon Bedrock AgentCore: Fundamentos, Primitivas e Infraestructura Agencial

Contexto Estratégico y Paradigma de Producción Agencial

La transición de la Inteligencia Artificial Generativa desde prototipos conceptuales locales hacia sistemas agenciales autónomos en entornos de producción representa una transformación de gran calado en la ingeniería de software empresarial. Aunque marcos de trabajo de código abierto como LangGraph, CrewAI, LlamaIndex, AutoGen o Strands han facilitado la definición del bucle de razonamiento y la lógica de los agentes, la infraestructura subyacente necesaria para operar estas soluciones a escala masiva introduce una complejidad operativa sustancial. Entre estos desafíos operacionales destacan la gestión de la persistencia de estado a largo plazo, el aislamiento de entornos para la ejecución de código, la intercepción de seguridad en tiempo real, la federación de identidades delegadas y la trazabilidad distribuida.
Amazon Bedrock AgentCore resuelve esta problemática mediante la desacoplación explícita entre la lógica de aplicación agencial y la capa de infraestructura que la sostiene. Diseñada como una plataforma serverless, modular y agnóstica tanto respecto al modelo de lenguaje fundamentativo como al marco de desarrollo elegido, AgentCore estandariza el ciclo de vida operativo de los agentes de IA en tres fases integradas: Construcción (Build), Despliegue (Deploy) y Evaluación (Assess). Esta arquitectura componible permite a las organizaciones evitar el bloqueo con proveedores específicos y evolucionar sus sistemas agenciales incorporando capacidades nativas de gobernanza, conectividad y análisis operativo sin reestructurar la lógica de negocio existente.

Componentes de la Fase de Construcción (Build): Capacidades Nativas y Gobernanza

La fase de construcción abarca el conjunto de servicios encargados de proveer capacidades de ejecución, autenticación, persistencia y control de herramientas para los agentes autónomos.

Entornos de Ejecución Especializados: AgentCore Browser y Code Interpreter

Para interactuar con el entorno digital moderno, los agentes requieren ejecutar tareas que sobrepasan las capacidades del razonamiento puramente probabilístico de los modelos de lenguaje. AgentCore Browser responde a la necesidad de interactuar con la web al proporcionar un entorno administrado y serverless para la ejecución de navegadores sin

interfaz gráfica (headless). Construido para escalar automáticamente de cero a cientos de sesiones simultáneas, este componente incorpora mecanismos avanzados para mitigar bloqueos por CAPTCHA, inyectar perfiles empresariales y enrutamiento a través de proxies corporativos. La integración técnica se realiza mediante bibliotecas estándar como Playwright o motores especializados como Nova Act, permitiendo al agente navegar por sitios web, interactuar con el Modelo de Objetos del Documento (DOM) y extraer información estructurada. Para fines de auditoría y depuración, AgentCore Browser incluye las funcionalidades Live View y Session Replay, las cuales registran síncronamente la secuencia visual y los eventos de red generados durante la sesión de navegación.

Por su parte, cuando las tareas agenciales exigen cálculos matemáticos de alta precisión, análisis de datos masivos o transformación dinámica de archivos, AgentCore Code Interpreter suministra un entorno de sandbox seguro basado en microVMs aisladas por sesión. Este componente permite la escritura y ejecución dinámica de código en Python, JavaScript y TypeScript. El modelo de aislamiento computacional impone barreras estrictas a nivel de CPU y memoria, impidiendo la contaminación cruzada entre sesiones o la exfiltración de credenciales del sistema host. El entorno incluye bibliotecas preinstaladas para análisis científico e integra almacenamiento persistente en sesión que admite la subida directa de archivos inline de hasta 100 MB y transferencias de mayor volumen mediante conectores directos con Amazon S3 de hasta 5 GB. A nivel de gobernanza, todas las ejecuciones de comandos de terminal e interacciones de red se canalizan a través de roles de ejecución de AWS IAM y quedan registradas en AWS CloudTrail. El esquema económico del servicio opera por consumo estricto por segundo a $0.0895 por vCPU-hora y $0.00945 por GB-hora de memoria, eximiendo de cobro los tiempos de inactividad y espera de entrada/salida.

Interoperabilidad de Herramientas y Descubrimiento Semántico: AgentCore Gateway y Registry

AgentCore Gateway actúa como la capa unificada de integración que transforma interfaces de programación de aplicaciones (APIs) tradicionales, funciones de AWS Lambda y servicios empresariales en herramientas estandarizadas consumibles por los agentes. Gateway adopta de forma nativa la especificación del protocolo Model Context Protocol (MCP), lo que permite conectar servidores MCP existentes mediante un enfoque sin código de infraestructura adicional.

Una innovación clave de AgentCore Gateway es la incorporación del descubrimiento semántico de herramientas. En lugar de saturar el contexto del modelo de lenguaje con esquemas de decenas de herramientas estáticas, Gateway utiliza modelos de embeddings (como Amazon Titan Text Embeddings) e índices vectoriales para realizar búsquedas semánticas dinámicas en tiempo real. Cuando el agente expresa una intención, Gateway identifica y retorna únicamente las herramientas relevantes para esa etapa específica de la conversación, optimizando la ventana de contexto y reduciendo la latencia general. Asimismo, Gateway implementa autenticación de doble cara, validando las credenciales de entrada del agente y gestionando la autenticación de salida hacia el recurso destino.

De forma complementaria, AgentCore Registry opera como el catálogo centralizado y gobernable dentro de la organización. En este registro se inscriben agentes, servidores MCP, herramientas, habilidades (skills) y recursos personalizados, facilitando su localización semántica y reutilización segura entre diferentes equipos y proyectos de la empresa.

Control de Acceso, Identidad Delegada y Gobernanza Determinista: AgentCore Identity y Policy

La delegación de autoridad a agentes autónomos introduce riesgos operativos si no se imponen límites de ejecución precisos. Para solucionar esto, la plataforma divide la gobernanza en dos componentes coordinados: AgentCore Identity y AgentCore Policy.
AgentCore Identity gestiona la autenticación y federación de identidades tanto para los agentes como para los usuarios finales a los que representan. Se integra directamente con proveedores de identidad empresariales (IdPs) compatibles con OAuth 2.0 y OpenID Connect, como Amazon Cognito, Okta, Microsoft Entra ID y Auth0. Mediante el patrón de intercambio de tokens en nombre del usuario (On-Behalf-Of), AgentCore Identity garantiza que el agente nunca asuma permisos superiores a los del usuario que inició la sesión, gestionando el almacenamiento de credenciales en un Token Vault cifrado mediante AWS KMS. Para interacciones que requieren validación humana explícita antes de invocar acciones sensibles, el servicio proporciona un Portal de Consentimiento personalizable.
Por otro lado, AgentCore Policy implementa un motor de control de acceso determinista que intercepta las llamadas a herramientas en tiempo real dentro del Gateway. Las políticas de gobernanza se redactan en lenguaje natural y se traducen automáticamente a Cedar, un lenguaje de código abierto diseñado para la evaluación de políticas de autorización mediante razonamiento formal. A diferencia de las verificaciones probabilísticas de los modelos de lenguaje, el motor de Cedar evalúa las intenciones agenciales mediante lógica formal determinista con latencias de sub-milisegundos, garantizando que el agente permanezca dentro de sus límites operativos sin degradar la experiencia de usuario.

Persistencia Contextual y Automatización Financiera: AgentCore Memory y Payments

La gestión del contexto resulta crítica para transformar interacciones aisladas en relaciones continuas y adaptativas. AgentCore Memory abstrae la infraestructura de base de datos subyacente para ofrecer soporte desacoplado a la memoria a corto y largo plazo. La memoria a corto plazo retiene el contexto dentro de una única sesión mediante un registro de eventos conversacionales, mientras que la memoria a largo plazo consolida conocimientos, preferencias del usuario y hechos extraídos a lo largo del tiempo.
Para procesar la memoria a largo plazo de forma automatizada, el servicio dispone de diversas estrategias integradas que operan en segundo plano:

- **Estrategia Semántica**: Indexa y recupera fragmentos de información basándose en la similitud vectorial del significado conceptual.
- **Estrategia de Preferencias de Usuario**: Aísla y actualiza dinámicamente gustos, restricciones y parámetros recurrentes expresados por el usuario.
- **Estrategia de Resumen**: Sintetiza historiales extensos para mantener la coherencia temática dentro de límites razonables de tokens.
- **Estrategia Episódica**: Almacena secuencias estructuradas de causa y efecto sobre cómo el agente resolvió un problema específico en interacciones previas.

Finalmente, el componente AgentCore Payments habilita la automatización de micro-transacciones financieras. Este módulo permite a los agentes realizar pagos de forma autónoma pero regulada para consumir APIs de pago por uso o adquirir servicios provistos por

servidores MCP externos, manteniendo un registro de auditoría cifrado.

Componentes de la Fase de Despliegue (Deploy): AgentCore Runtime e Infraestructura Serverless

El despliegue de agentes en entornos productivos exige una plataforma que elimine la gestión manual de servidores y garantice el aislamiento multinivel para cargas de trabajo heterogéneas.

Hosting Serverless y Ejecución Asíncrona de Larga Duración

AgentCore Runtime es el motor de ejecución serverless optimizado para hospedar agentes y herramientas independientemente del marco de trabajo o modelo utilizado. La infraestructura escala automáticamente desde cero hasta miles de solicitudes concurrentes, aplicando un esquema de cobro basado exclusivamente en los recursos activos consumidos durante la ejecución.
A nivel operativo, AgentCore Runtime resuelve la dualidad entre interacciones de baja latencia y procesamiento asíncrono pesado. El motor está diseñado para responder a llamadas conversacionales en tiempo real con arranques en frío mínimos (low cold-starts), mientras que simultáneamente ofrece capacidad para mantener ejecuciones de fondo de larga duración de hasta ocho horas continuas. Esto permite que un único agente atienda una consulta interactiva e inicie en paralelo un proceso asíncrono de análisis de datos o compilación de informes sin bloquear la interfaz del usuario ni arriesgar la pérdida de estado.

Desacoplamiento de Marcos de Trabajo y Protocolo Agent-to-Agent (A2A)

La flexibilidad de AgentCore Runtime reside en su diseño agnóstico respecto a las bibliotecas de desarrollo. Mediante el uso del SDK bedrock-agentcore para Python o la herramienta de línea de comandos AgentCore CLI (agentcore deploy), los desarrolladores pueden empaquetar código local construido sobre Strands, LangGraph, CrewAI, AutoGen o desarrollos a medida y desplegarlo en producción sin reescribir la lógica interna.
Para facilitar la colaboración en arquitecturas de múltiples agentes, Runtime incorpora soporte para el protocolo Agent-to-Agent (A2A). Bajo este estándar, cada agente desplegado expone una Tarjeta de Agente (*Agent Card*) estructurada mediante la cual publica sus capacidades, formatos de entrada y requerimientos de autorización. De este modo, los agentes pueden descubrirse semánticamente, negociar tareas y delegarse subprocesos entre sí de manera distribuida, superando las limitaciones de escalabilidad de las arquitecturas estrictamente jerárquicas.

Componentes de la Fase de Evaluación y Diagnóstico (Assess): Observabilidad y Refinamiento Continuo

Una vez desplegado el agente, la garantía de calidad y la alineación de su comportamiento requieren herramientas de monitoreo continuo y evaluación cualitativa.

Trazabilidad Distribuida y Telemetría: AgentCore Observability

AgentCore Observability proporciona visibilidad sobre la ejecución interna y las decisiones tomadas por los agentes. El servicio genera de manera nativa datos de telemetría basados en el estándar OpenTelemetry (OTel), capturando métricas como consumo de tokens de entrada y salida, latencia por turno conversacional, tasas de error y duración total de la sesión.
A través de la integración con Amazon CloudWatch y plataformas de monitoreo especializadas como Datadog o LangFuse, los equipos operativos pueden inspeccionar trazas distribuidas (*traces*) compuestas por tramos individuales (*spans*). Cada span registra la decisión tomada por el modelo de lenguaje, la llamada a la herramienta interceptada en Gateway, la consulta ejecutada en Memory y el resultado retornado por el entorno de ejecución, simplificando el diagnóstico cuando un agente entra en bucles de reintento o genera respuestas no alineadas.

Evaluación Cualitativa y Experimentación: AgentCore Evaluations y Refinements

Para asegurar que los agentes mantengan altos estándares de calidad a lo largo del tiempo, la plataforma incorpora los módulos AgentCore Evaluations y AgentCore Refinements.
AgentCore Evaluations ejecuta la puntuación continua de las interacciones agenciales tanto en tiempo real (evaluaciones online) como sobre conjuntos de datos históricos (evaluaciones batch). Utiliza evaluadores integrados y personalizados para medir criterios como la precisión contextualmente respaldada (*contextual grounding*), la relevancia de la respuesta, la seguridad en el uso de herramientas y la exactitud en la selección de parámetros de APIs.
Por su parte, AgentCore Refinements canaliza los hallazgos producidos por el módulo de evaluación para impulsar la mejora continua del sistema agencial. Este componente permite configurar experimentos A/B directamente en el entorno de producción, enrutando porcentajes del tráfico a distintas versiones de la lógica del agente, diferentes variantes de prompts o configuraciones alternativas de modelos. A través de las recomendaciones algorítmicas generadas por el sistema, los equipos de desarrollo pueden validar hipótesis de optimización basadas en datos empíricos antes de realizar despliegues masivos.

Matriz Comparativa de Componentes de Amazon Bedrock AgentCore

Componente	Fase del Ciclo de Vida	Función Principal	Integraciones y Protocolos Clave	Especificaciones Técnicas y Aislamiento
AgentCore Browser	Construcción (Build)	Navegación y automatización web administrada.	Playwright, Nova Act, Proxies Corporativos.	Escalado de 0 a 100+ sesiones, reducción de CAPTCHA, auditoría con Live View y Session Replay.
AgentCore Code Interpreter	Construcción (Build)	Ejecución segura de código en	Python, JavaScript,	MicroVMs por sesión,

Componente	Fase del Ciclo de Vida	Función Principal	Integraciones y Protocolos Clave	Especificaciones Técnicas y Aislamiento
		sandbox.	TypeScript, AWS S3, CloudTrail.	$0.0895/vCPU-h + $0.00945/GB-h, archivos inline hasta 100MB e historias S3 hasta 5GB.
AgentCore Gateway	Construcción (Build)	Conversión de APIs y Lambda en herramientas agenciales.	Model Context Protocol (MCP), OpenAPI v3, AWS Lambda.	Búsqueda semántica de herramientas vía Titan Text Embeddings, autenticación dual, tasa de límite (429).
AgentCore Identity	Construcción (Build)	Gestión centralizada de identidades y permisos.	OAuth 2.0, OIDC, Cognito, Okta, Entra ID, Auth0.	Flujo On-Behalf-Of (OBO), Token Vault cifrado en KMS, Portal de Consentimiento.
AgentCore Policy	Construcción (Build)	Control determinista e intercepción de herramientas.	Lenguaje Cedar, AgentCore Gateway.	Evaluación formal determinista con tiempo de respuesta de sub-milisegundos.
AgentCore Memory	Construcción (Build)	Persistencia y gestión de contexto conversacional.	OpenSearch Serverless, DynamoDB.	Estrategias: Semántica, Preferencias, Resumen y Episódica; acceso multi-cuenta.
AgentCore Registry	Construcción (Build)	Catálogo centralizado de recursos de IA.	Protocolos MCP y A2A, Bedrock Catalog.	Descubrimiento semántico dinámico de agentes, herramientas y habilidades.
AgentCore Payments	Construcción (Build)	Automatización de micro-transacciones financieras.	Proveedores IdP, Servidores MCP pagados.	Cifrado de transacciones y cuotas financieras prefijadas.
AgentCore Runtime	Despliegue (Deploy)	Hosting serverless e infraestructura agencial.	Strands, LangGraph, CrewAI, AutoGen, Protocolo A2A.	Aislamiento de sesión, llamadas síncronas de baja latencia y tareas

Componente	Fase del Ciclo de Vida	Función Principal	Integraciones y Protocolos Clave	Especificaciones Técnicas y Aislamiento
				asíncronas de hasta 8 horas.
AgentCore Observability	Evaluación (Assess)	Telemetría, trazabilidad y monitoreo.	OpenTelemetry (OTel), CloudWatch, Datadog, LangFuse.	Spans y traces completos para métricas de tokens, latencia y errores.
AgentCore Evaluations	Evaluación (Assess)	Calificación cualitativa y cuantitativa de respuestas.	Evaluadores nativos y personalizados de Bedrock.	Evaluaciones batch y online para medir fundamentación contextual y alucinaciones.
AgentCore Refinements	Evaluación (Assess)	Optimización continua y experimentación agencial.	AgentCore Runtime, AgentCore Evaluations.	Pruebas A/B en producción y recomendaciones algorítmicas de mejora.

Conclusiones e Implicaciones de Ingeniería

El análisis detallado de Amazon Bedrock AgentCore confirma que la plataforma constituye un avance significativo para la industrialización de la Inteligencia Artificial Agencial. Al asumir la complejidad intrínseca de la infraestructura (aislamiento de ejecución, gobernanza determinista, descubrimiento de herramientas y trazabilidad distribuida), AgentCore permite que las organizaciones escalen sus proyectos de IA sin necesidad de construir capas intermedias de software propietario.

Desde una perspectiva de arquitectura de sistemas, destacan tres implicaciones clave:

1. **Gobernanza Híbrida y Confiabilidad**: La integración de AgentCore Policy y Cedar permite combinar la flexibilidad de los modelos probabilísticos con la rigidez de las reglas de autorización deterministas, mitigando los riesgos de ejecución no deseada en sistemas autónomos.
2. **Eficiencia en la Ventana de Contexto**: La combinación del descubrimiento semántico de herramientas en AgentCore Gateway y las estrategias avanzadas de almacenamiento en AgentCore Memory optimiza el uso de tokens, reduciendo significativamente los costos de inferencia y la latencia en conversaciones complejas.
3. **Independencia de Stack y Portabilidad**: Al mantenerse neutral frente a los marcos de desarrollo y modelos de lenguaje, AgentCore Runtime ofrece garantías de longevidad para las inversiones en software de las empresas, permitiendo la rápida adopción de nuevos modelos a medida que evolucionan en el mercado.

En síntesis, Amazon Bedrock AgentCore proporciona una infraestructura sólida y estandarizada que permite cerrar la brecha entre la experimentación y el despliegue de agentes autónomos seguros, escalables y eficientes a nivel empresarial.

Obras citadas

1. Amazon Bedrock AgentCore: The Infrastructure Layer for Enterprise, https://www.devoteam.com/expert-view/amazon-bedrock-agentcore/ 2. Domina la IA con AWS AgentCore - ACKstorm, https://www.ackstorm.com/blog/aws-agentcore/ 3. bedrock-agentcore - PyPI, https://pypi.org/project/bedrock-agentcore/ 4. Overview - Amazon Bedrock AgentCore - AWS Documentation, https://docs.aws.amazon.com/bedrock-agentcore/latest/devguide/what-is-bedrock-agentcore.html 5. Amazon Bedrock AgentCore - AWS, https://aws.amazon.com/bedrock/agentcore/ 6. aws-samples/sample-bedrock-agentcore-with-strands-and-nova, https://github.com/aws-samples/sample-bedrock-agentcore-with-strands-and-nova 7. AWS AgentCore Code Interpreter | Ry Walker Research, https://rywalker.com/research/agentcore-code-interpreter 8. Application Services – Artificial Intelligence - AWS, https://aws.amazon.com/blogs/machine-learning/category/application-services/feed/ 9. Preguntas frecuentes sobre Amazon Bedrock AgentCore - AWS, https://aws.amazon.com/es/bedrock/agentcore/faqs/ 10. Release Notes - AWS SDK for SAP ABAP - API Documentation, https://docs.aws.amazon.com/sdk-for-sap-abap/v1/api/latest/release_notes.html 11. LLMOps in Production: Another 419 Case Studies of What Actually, https://www.zenml.io/blog/llmops-in-production-another-419-case-studies-of-what-actually-works 12. Amazon Bedrock AgentCore | Elastic integrations, https://www.elastic.co/docs/reference/integrations/aws_bedrock_agentcore 13. Task-Scoped Authorization for AI Agents via Natural Language Slices, https://arxiv.org/pdf/2603.17170